Definição de Projeto

Título da proposta

- Análise do Impacto de Múltiplas Fontes Textuais em Português na Previsão Diária do Ibovespa via Embeddings de LLM e LSTM

Artigos base

- FinBERT-LSTM (ACM 2024): https://dl.acm.org/doi/10.1145/3694860.3694870
- Comparative study news sentiment + stock (PLOS ONE 2023): https://doi.org/10.1371/journal.pone.0284695
- FinBERT original: https://arxiv.org/abs/1908.10063

Códigos base

- FinBERT (ProsusAI): https://huggingface.co/ProsusAI/finbert
- BERTimbau (NeuralMind): https://huggingface.co/neuralmind/bert-base-portuguese-cased

Dados para validação

- Série histórica diária do Ibovespa (^BVSP) de 2019 a 2024 via yfinance (~1.250 pregões)
- Manchetes diárias do InfoMoney e Valor Econômico via RSS
- Notas e comunicados das reuniões do COPOM (site público do Banco Central)
- Tweets de analistas financeiros brasileiros via Twitter/X API

Resumo da proposta

O trabalho investiga qual tipo de fonte textual em português — jornais financeiros, comunicados do Banco Central ou redes sociais — tem maior poder preditivo sobre o fechamento diário do Ibovespa (D+1). A contribuição central é um ablation study com cinco configurações progressivas: ARIMA puro (baseline), LSTM só com preço histórico, LSTM + embeddings de jornais, LSTM + embeddings de jornais e COPOM, e LSTM com todas as três fontes. Os embeddings são gerados por BERTimbau e FinBERT — comparação em contexto financeiro PT-BR. Comunicados do COPOM, por serem textos longos e técnicos, são processados por zero-shot para extração de sinal de política monetária antes de entrar no modelo. A avaliação usa MAE, RMSE e Directional Accuracy por configuração, permitindo comparação direta com a literatura e resposta empírica sobre quais fontes realmente movem o mercado brasileiro.